MNIST VERİ SETİ İLE MLP TABANLI EL YAZISI RAKAM TANIMA

Hazırlayan: Metehan Doğan
Öğrenci Numarası: 269797012

Amaç:

Çalışmanın amacı, MNIST el yazısı rakam veri seti kullanılarak bir Multi-Layer Perceptron (MLP) modeli geliştirmek, modeli eğitmek ve model yapılandırmalarının performansını karşılaştırmak, el ile yazılan okul numarasına, ön işleme uygulayarak modelin kullandığı MNIST veri setine uygun hale getirmek ve model başarısını değerlendirmektir.

Veri seti ve ön işleme:

Deneyde 0 ile 9 arasındaki rakamlardan oluşan ve 10 farklı sınıf içeren MNIST veri seti eğitim, test ve doğrulama için kullanılmıştır. Veri setindeki görüntüler 28x28 piksel boyutunda ve gri tonlamalıdır. 60000 verilik eğitim/doğrulama veri seti ve 10000 verilik test veri seti olarak ayrılmıştır. Deney sonunda modelin gerçek hayattaki el yazıları hakkındaki başarısını değerlendirmek üzere el yazısı ile oluşturduğu rakamlar, MNIST veri setine uygun hale getirmek için rakamlar 28x28 piksel boyutuna ve gri tonlamalı hale getirilmiştir.

Model Mimarisi ve Deney Ayarları:

MNIST veri setindeki el yazısı rakamlarını sınıflandırmak amacıyla çok katmanlı algılayıcı (MLP) mimarisi kullanılmıştır. Model, 28 × 28 piksel boyutundaki gri tonlamalı görüntüler giriş olarak alınmakta ve 784 elemanlı bir vektöre dönüştürülerek ağa aktarılmaktadır. Temel MLP modelinin katman yapısı Şekil 1'de gösterilmiştir.

```python
class MLP(nn.Module):
    def __init__(
        self,
        input_size: int = 784,
        hidden1: int = 256,
        hidden2: int = 128,
        num_classes: int = 10,
    ):
        super().__init__()

        # MLP modelinin katmanlarının sırayla tanımlanması.
        self.network = nn.Sequential(
            # 28x28 boyutundaki görüntüyü 784 elemanlı vektöre dönüştür.
            nn.Flatten(),
            # Birinci gizli katman: 784 girişten 256 nörona geçiş
            nn.Linear(input_size, hidden1),
            # Modele doğrusal olmayan öğrenme yeteneği kazandır.
            nn.ReLU(),
            # İkinci gizli katman: 256 nörondan 128 nörona geçiş.
            nn.Linear(hidden1, hidden2),
            # İkinci gizli katmanda da ReLU aktivasyonunu uygula.
            nn.ReLU(),
            # Çıkış katmanı: 10 rakam sınıfı için skor üret.
            nn.Linear(hidden2, num_classes),
        )
```

Şekil 1 : Temel MLP modelinin katman yapısı.

Temel modelde, 256 ve 128 nörondan oluşan iki gizli katman bulunmaktadır. Gizli katmanlarda ReLU aktivasyon fonksiyonu kullanılmıştır. Çıkış katmanı ise 0–9 arasındaki rakamları temsil eden 10 nörondan oluşmaktadır. Sınıflandırma kaybını hesaplamak için CrossEntropyLoss, modelin ağırlıklarını güncellemek için Adam optimizasyon algoritması kullanılmıştır.

Deneylerde öğrenme oranı 0,001, batch size 128 ve epoch sayısı 10 olarak belirlenmiştir. Deneylerin tekrarlanabilirliğini artırmak amacıyla rastgelelik tohumu (seed) 42 olarak ayarlanmıştır. Eğitim verisinin 55.000 örneği modelin eğitimi, 5.000 örneği doğrulama amacıyla kullanılmıştır. Ayrıca, 10.000 görüntüden oluşan test veri seti eğitim ve model seçimi sürecinden ayrı tutulmuştur. Temel modelde kullanılan hiperparametreler Şekil 2'de, veri yükleyicileri, kayıp fonksiyonu ve optimizasyon ayarları ise Şekil 3'te verilmiştir.

```python
# Model eğitimi için kullanılacak hiperparametreler
SEED = 42
BATCH_SIZE = 128
EPOCHS = 10
LEARNING_RATE = 0.001
# MLP modelindeki iki gizli katmanın nöron sayıları
HIDDEN1 = 256
HIDDEN2 = 128
```

Şekil 2 : Temel MLP deneyinde kullanılan hiperparametreler.

```python
# Eğitim ve doğrulama verilerini yükler.
train_loader, val_loader, _ = get_data_loaders(
    data_dir=str(BASE_DIR / "data"),
    batch_size=BATCH_SIZE,
    seed=SEED,
)

# İki gizli katmanlı MLP modelini oluşturur.
model = MLP(
    hidden1=HIDDEN1,
    hidden2=HIDDEN2,
).to(device)

# Çok sınıflı sınıflandırma için kayıp fonksiyonunu belirlenmesi.
criterion = nn.CrossEntropyLoss()

# Model ağırlıklarını güncellemek için Adam optimizer kullanımı.
optimizer = torch.optim.Adam(
    model.parameters(),
    lr=LEARNING_RATE,
)
```

Şekil 3 : Veri yükleyicileri, kayıp fonksiyonu ve optimizasyon ayarları.

Hiperparametre karşılaştırması yapmak amacıyla ikinci bir MLP modeli oluşturulmuştur. Bu modelde yalnızca gizli katmanlardaki nöron sayıları 128 ve 64 olarak değiştirilmiş; öğrenme oranı, batch size, epoch sayısı ve optimizasyon algoritması temel modelle aynı tutulmuştur. Böylece gizli katman boyutlarının modelin başarımı ve eğitim süresi üzerindeki etkisi karşılaştırılmıştır. Küçük MLP modelinde kullanılan hiperparametreler Şekil 4'te gösterilmiştir.

```
SEED = 42
BATCH_SIZE = 128
EPOCHS = 10
LEARNING_RATE = 0.001

# Temel modele göre daha az nöron içeren MLP mimarisi.
HIDDEN1 = 128
HIDDEN2 = 64
```

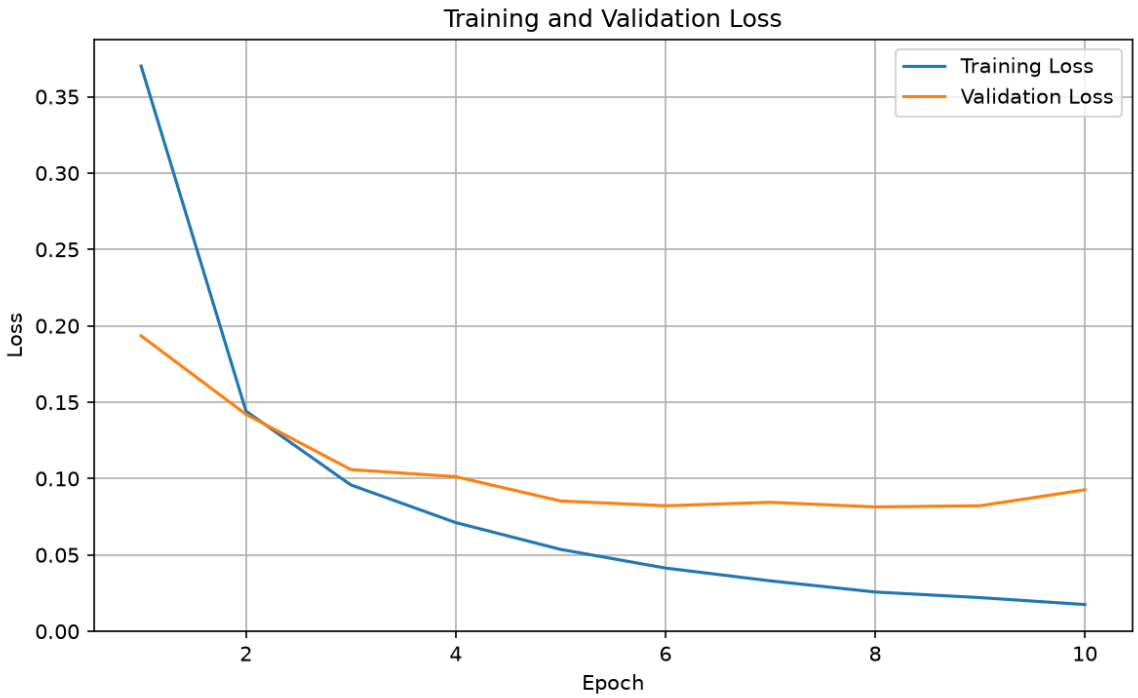
Şekil 4 : Küçük MLP modelinde kullanılan hiperparametreler.

İkinci deneyde, temel modelin gizli katmanlarındaki nöron sayıları sırasıyla 256'dan 128'e ve 128'den 64'e düşürülmüştür. Diğer hiperparametreler (batch size, epoch sayısı ve öğrenme oranı) sabit tutulmuştur. Böylece model boyutunun performans ve eğitim süresi üzerindeki etkisi incelenmiştir.

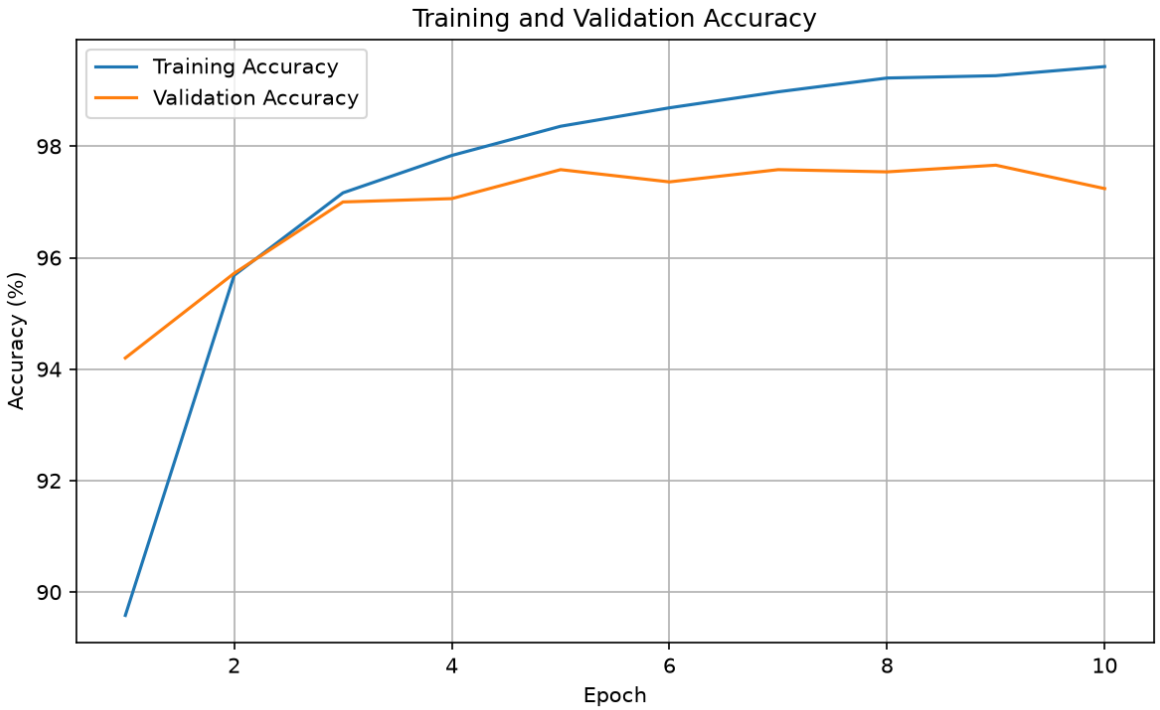
Deney sonuçları ve karşılaştırma

Temel MLP Modelinin Eğitim Sonuçları:

Temel MLP modelinin eğitimi, CPU üzerinde 10 epoch sonunda yaklaşık 98,72 saniyede tamamlanmıştır. Eğitim ve doğrulama kaybı (loss) ile doğruluk (accuracy) değerleri takip edilmiştir. Eğitim sürecindeki değişimleri incelemek için kayıp ve doğruluk grafikleri oluşturulmuş, her epoch için elde edilen sonuçlar ayrıca tabloda sunulmuştur. Böylece modelin öğrenme süreci, doğrulama performansı ve en uygun modelin seçilmesi değerlendirilmiştir. Temel MLP modelinin eğitim ve doğrulama kaybındaki değişim Şekil 5'te, doğruluk değerlerindeki değişim ise Şekil 6'da gösterilmiştir.



Şekil 5 : Temel MLP modelinin loss grafiği



Şekil 6 : Temel MLP modelinin doğruluk grafiği

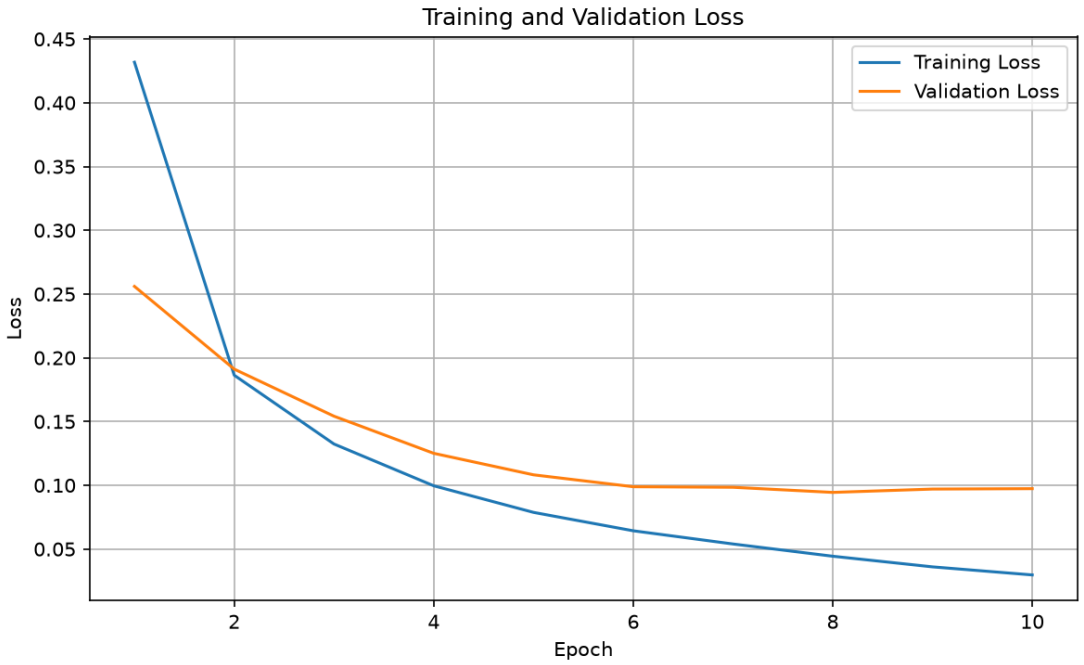
Eğitim süreci boyunca eğitim kaybı düzenli olarak azalırken eğitim doğruluğu (training accuracy) artmıştır. Doğrulama kaybı 8. epoch'ta en düşük değer olan 0,0814'e ulaşmıştır. En yüksek doğrulama doğruluğu (validation accuracy) ise 9. epoch'ta %97,66 olarak elde edilmiştir. Model seçimi en düşük doğrulama kaybına göre yaptığımız için 8. epoch'ta kaydedilen model kullanılmıştır. Her epoch için elde edilen eğitim ve doğrulama değerleri Tablo 1'de ayrıntılı olarak sunulmuştur.

Tablo 1 : Temel MLP modelinin epoch bazında eğitim ve doğrulama sonuçları.

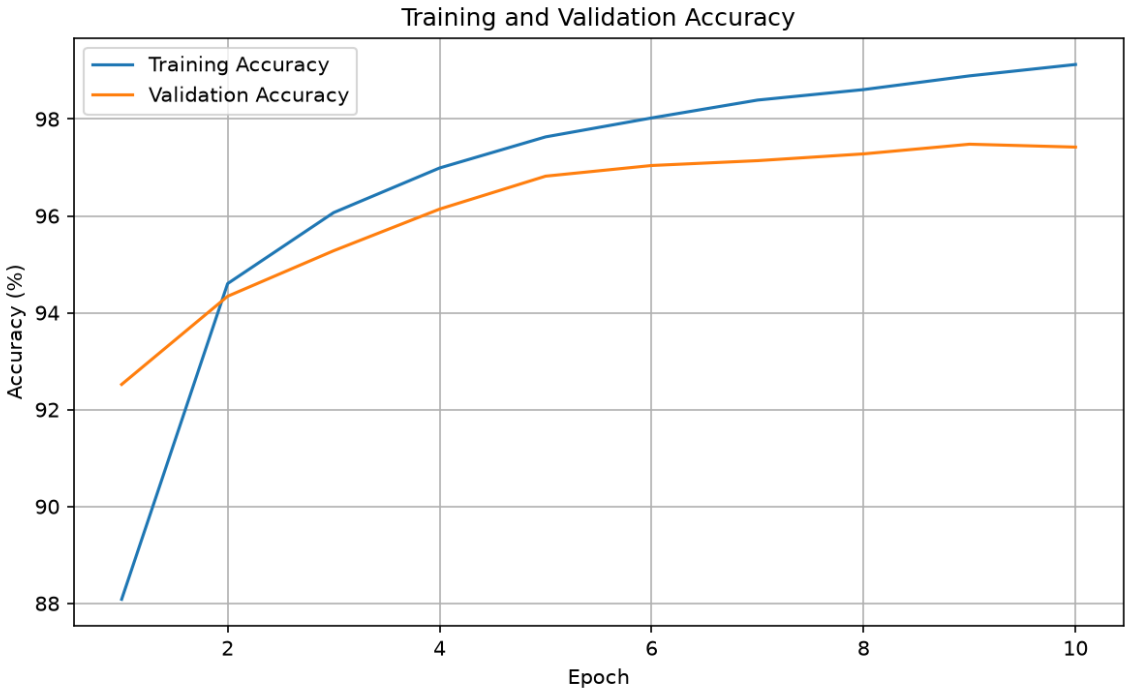
epoch	train_loss	val_loss	train_accuracy (%)	val_accuracy (%)
1	0.3700	0.1934	89.58	94.2
2	0.1441	0.1420	95.68	95.72
3	0.0958	0.1059	97.16	97.0
4	0.0711	0.1012	97.83	97.06
5	0.0536	0.0853	98.36	97.58
6	0.0414	0.0821	98.69	97.36
7	0.0330	0.0844	98.98	97.58
8	0.0257	**0.0814**	99.22	97.54
9	0.0220	0.0822	99.27	**97.66**
10	0.0175	0.0926	99.42	97.24

Küçük MLP Modelinin Eğitim Sonuçları:

Temel modelle karşılaştırma yapmak amacıyla gizli katmanlarında 128 ve 64 nöron bulunan küçük MLP modeli 10 epoch süren eğitimi CPU üzerinde yaklaşık 83,27 saniyede tamamlanmıştır. Eğitim ve doğrulama kaybı ile doğruluk değerleri takip edilerek modelin öğrenme süreci ve performansı incelenmiştir. Küçük MLP modelinin eğitim ve doğrulama kaybı Şekil 7'de, doğruluk değerleri ise Şekil 8'de gösterilmiştir.



Şekil 7 : Küçük MLP modelinin loss grafiği



Şekil 8 : Küçük MLP modelinin doğruluk grafiği

Tablo 2: Küçük MLP modelinin epoch bazında eğitim ve doğrulama sonuçları

epoch	train_loss	val_loss	train_accuracy	val_accuracy
1	0.4318	0.2559	88.08	92.52
2	0.1863	0.1911	94.60	94.34
3	0.1323	0.1541	96.06	95.28
4	0.0995	0.1250	96.99	96.14
5	0.0787	0.1082	97.63	96.82
6	0.0643	0.0988	98.02	97.04
7	0.0539	0.0984	98.39	97.14
8	0.0443	**0.0944**	98.60	97.28
9	0.0360	0.0970	98.89	**97.48**
10	0.0296	0.0973	99.12	97.42

Küçük MLP modelinde eğitim kaybı epoch sayısı arttıkça azalmış ve eğitim doğruluğu yükselmiştir. Doğrulama kaybı 8. epoch'ta en düşük değer olan 0,0944'e ulaşmıştır. En yüksek doğrulama doğruluğu ise 9. epoch'ta %97,48 olarak elde edilmiştir. En düşük doğrulama kaybına sahip model 8. epoch'ta kaydedilmiştir. Modelin epoch bazındaki eğitim ve doğrulama sonuçları Tablo 2'de verilmiştir.

Modellerin Karşılaştırması:

Tablo 3: Modellerin karşılaştırılması

Ölçüt	Temel MLP	Küçük MLP
Gizli katmanlar	256, 128	128, 64
En düşük doğrulama kaybı	0,0814	0,0944
En yüksek doğrulama doğruluğu	%97,66	%97,48
Eğitim süresi	98,72 sn	83,27 sn

İki modelin doğrulama performansları ve eğitim süreleri Tablo 3'te karşılaştırılmıştır. Temel MLP modeli, küçük MLP modeline kıyasla daha düşük doğrulama kaybı ve biraz daha yüksek doğrulama doğruluğu elde etmiştir. Küçük MLP modeli eğitim süresini yaklaşık 15,45 saniye azaltmıştır. Bu sonuçlar, gizli katmanlardaki nöron sayısının azaltılmasının eğitim süresini kısaltabildiğini, ancak modelin doğrulama performansında küçük bir düşüşe yol açabildiğini göstermektedir.

Test Sonuçları:

Seçilen temel MLP modelinin test kümesindeki genel performans ölçütleri Tablo 4'te sunulmuştur.

Tablo 4: Temel MLP modelinin test sonuçları.

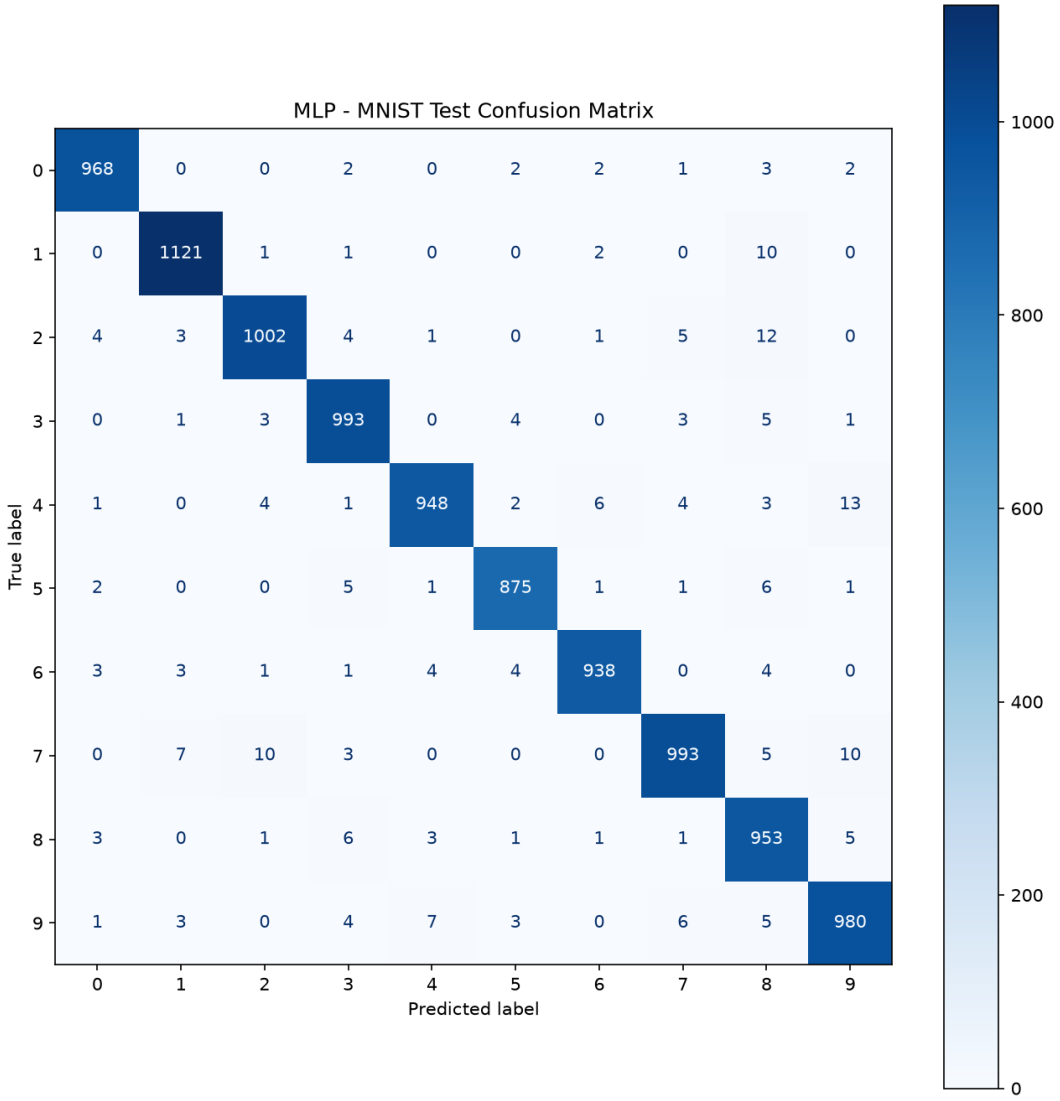
Ölçüt	Değer
selected_epoch(Seçilen Epoch)	8
test_loss(Test Kaybı)	0.0774
test_accuracy(Test doğruluğu)	97.71

Doğrulama kümesinde elde edilen en düşük kayıp değerine göre seçilen 8. epoch modelinin performansı, test veri kümesi üzerinde değerlendirilmiştir. Model, 10.000 test görüntüsünün 9.771'ini doğru sınıflandırarak %97,71 doğruluk ve 0,0774 test kaybı elde etmiştir. Bu sonuçlar, modelin eğitim sırasında kullanılmayan MNIST görüntülerindeki sınıflandırma başarısının yüksek olduğunu göstermektedir.

Tablo 5: Temel MLP modelinin test kümesindeki sınıf bazlı sınıflandırma sonuçları

Rakam	Precision	Recall	F1-score	Gerçek örnek sayısı (Support)
0	0.9857	0.9878	0.9867	980
1	0.9851	0.9877	0.9864	1135
2	0.9804	0.9709	0.9757	1032
3	0.9735	0.9832	0.9783	1010
4	0.9834	0.9654	0.9743	982
5	0.9820	0.9809	0.9815	892
6	0.9863	0.9791	0.9827	958
7	0.9793	0.9660	0.9726	1028
8	0.9473	0.9784	0.9626	974
9	0.9684	0.9713	0.9698	1009

Modelin her bir rakam sınıfına ait precision, recall, F1-score ve support değerleri Tablo 5'te verilmiştir. Sınıflandırma raporuna göre model, test verisinde tüm rakam sınıflarında yüksek performans göstermiştir. En yüksek F1-score 0 rakamında 0,9867, en düşük F1-score ise 8 rakamında 0,9626 olarak ölçülmüştür. Bu değerler arasındaki fark yalnızca 0,0241 (yaklaşık 2,41 yüzde puanı) olduğundan, sınıflar arasındaki performans farkı oldukça düşüktür. Bu sonuç, modelin farklı rakam sınıflarında genel olarak tutarlı ve başarılı bir sınıflandırma performansı sergilediğini göstermektedir.

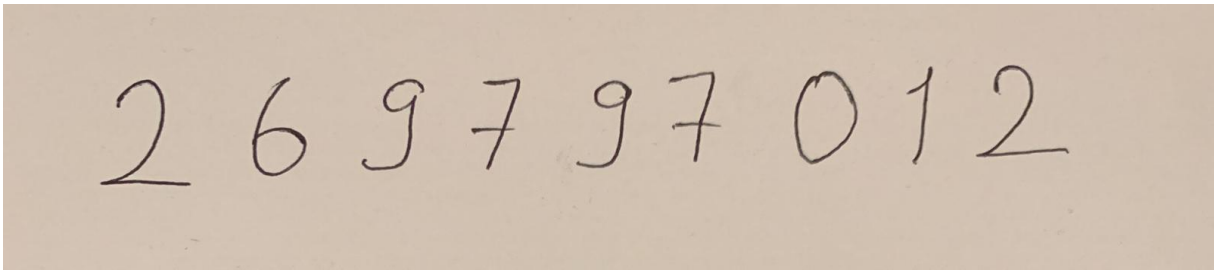


Şekil 9 : Temel MLP modelinin MNIST test kümesindeki karmaşıklık matrisi.

Sınıflandırma sonuçlarının sınıflara göre dağılımı Şekil 9'daki karmaşıklık matrisi üzerinden incelenmiştir. Karmaşıklık matrisinin köşegenindeki değerler doğru sınıflandırılan görüntüleri, köşegen dışındaki değerler ise yanlış sınıflandırmaları göstermektedir. Model çoğu rakamı doğru sınıflandırmıştır. Bununla birlikte bazı rakamlar birbiriyle karıştırılmıştır. Örneğin gerçek 4 rakamlarının 13'ü 9, gerçek 2 rakamlarının 12'si 8 olarak tahmin edilmiştir. Bu sonuçlar, modelin genel doğruluğu yüksek olsa da belirli rakam çiftlerinde sınıflandırma hataları yapabildiğini göstermektedir.

Kendi el yazımdaki rakamlarla modelin değerlendirilmesi:

MNIST veri seti üzerinde eğitilen modelin, eğitim sırasında karşılaşmadığı el yazısı görüntülerindeki performansını incelemek amacıyla öğrencinin numarası el yazısıyla yazıldı. Yazılan öğrenci numarasının görüntüsünü modele vermeden önce rakamlar ayrı ayrı kırpılarak kaydedildi. Öğrenci numarasının orijinal görüntüsü Şekil 10'da gösterilmiştir.



Şekil 10 : El yazısıyla yazılan öğrenci numarasının orijinal görüntüsü.

Görüntülerin ön işlenmesi:

Görüntüler tek kanallı gri tonlamalı biçime dönüştürülmüş, arka planın parlaklığına göre gerektiğinde renkler ters çevrilmiştir ve eşikleme uygulanarak rakam ile arka plan birbirinden ayrılmıştır. Rakamın çevresindeki boş alanlar kaldırılarak görüntünün yalnızca rakamı içeren bölümü elde edilmiştir. Görüntünün en boy oranı korunarak boyutu en fazla 20 × 20 piksel olacak şekilde küçültülmüş ve siyah arka planlı 28 × 28 piksellik bir tuvalin ortasına yerleştirilmiştir. Hazırlanan görüntüler PNG formatında kaydedilmiş ve model tahmini sırasında transforms.ToTensor() kullanılarak piksel değerleri 0–255 aralığından 0–1 aralığına dönüştürülmüştür.

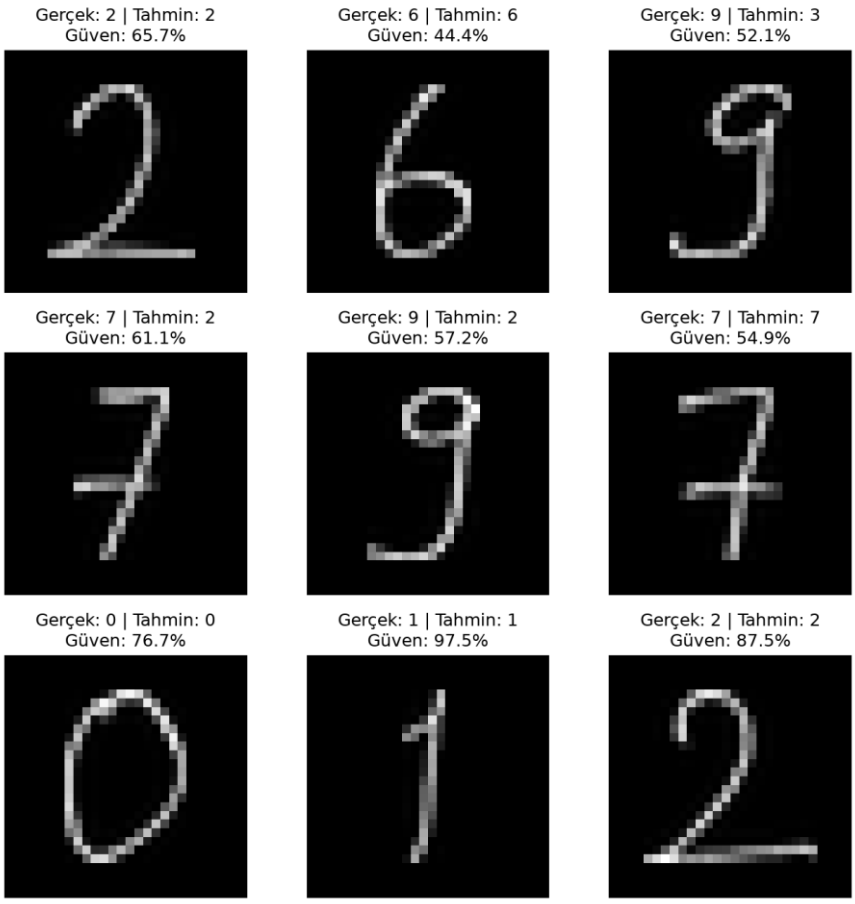


Şekil 11: Modelin giriş formatına dönüştürülen el yazısı rakamları (28 × 28 piksel).

Bu işlemlerle görüntü boyutu, renk biçimi ve piksel değerleri modelin beklediği giriş formatına uygun hâle getirilmiştir.

Modelin tahmin sonuçları:

Ön işleme işlemlerinin ardından hazırlanan dokuz rakam görüntüsü, temel MLP modeline verildi. Her görüntü için modelin tahmini ve tahmin güven skoru kaydedildi. Modelin her rakam için ürettiği tahminler ve tahmin güven skorları Şekil 12'de gösterilmiştir.



Şekil 12: Temel MLP modelinin kendi el yazısı rakamları üzerindeki tahmin sonuçları.

Sonuçların Değerlendirilmesi:

MNIST test kümesinde %97,71 doğruluk elde eden modelin kendi el yazısı görüntülerindeki doğruluğu %66,67 olmuştur. İki sonuç arasındaki fark, modelin standart MNIST görüntülerinde elde ettiği başarının farklı yazım biçimlerine sahip görüntülere aynı ölçüde yansımadığını göstermektedir.

Bu farkın olası nedenleri arasında rakamların yazım biçimi, çizgi kalınlığı, rakamın görüntü içindeki konumu ve ön işleme sırasında uygulanan eşikleme işlemi bulunmaktadır. Görüntüler 28 × 28 piksele dönüştürülmüş olsa da rakamların şekil özellikleri MNIST örneklerinden farklı olabilir. Bu durum, eğitim verisi ile yeni veriler arasındaki dağılım farkına (distribution shift) ve modelin genelleme performansına örnek oluşturmaktadır.

Bununla birlikte, yalnızca dokuz görüntüden oluşan bu küçük örneklem, modelin genel el yazısı tanıma başarısını belirlemek için yeterli değildir. Sonuçlar, yalnızca kullanılan kişisel rakam görüntüleri üzerindeki performans olarak değerlendirilmelidir.

Genel Değerlendirme ve Sonuç

Bu çalışmada, MNIST veri seti kullanılarak MLP tabanlı bir el yazısı rakam tanıma modeli geliştirilmiştir. İki gizli katmana sahip model, 10 epoch'tan sonra test veri setinde %97,71 başarı oranı elde etmiştir. Nöron sayıları azaltılan MLP modeli, ana modele göre daha kısa sürede tamamlanmış, ancak doğrulama başarısında küçük bir düşüş yaşamıştır. Eğitimdeki loss ve accuracy değerleri değerlendirildiğinde, epoch sayısı arttıkça eğitim kaybının azaldığı ve eğitim doğruluğunun yükseldiği görülmüştür. Temel modelin eğitim doğruluğu son epoch'ta %99,43'e ulaşırken doğrulama doğruluğu en yüksek %97,66 olmuştur. Son epoch'ta doğrulama doğruluğunun düşmesi, modelin eğitim verisine uyumunun artmasına rağmen doğrulama performansının iyileşmediğini göstermektedir.

Model el yazımla hazırladığım 9 rakamın 6'sını doğru tahmin edebilmiş ve doğruluk oranı %66,67 olarak ölçülmüştür. Bu azalma, modelin eğitim ve test verilerinden farklı örneklerde daha fazla zorluk yaşadığını ortaya koymaktadır. Bu performans düşüşü, MNIST veri seti ile kişisel el yazısı örnekleri arasındaki görsel farklılıklardan kaynaklanabilir. Ayrıca değerlendirmenin yalnızca dokuz örnekle yapılması, sonuçların genellenebilirliğini sınırlandırmaktadır.

Sonuç olarak, çalışma kapsamında MLP modelinin MNIST veri setindeki rakamları yüksek doğrulukla sınıflandırabildiği, ancak farklı el yazısı örneklerine genelleme konusunda geliştirmeye ihtiyaç duyduğu gözlemlenmiştir. Bu durum, dağılım kayması (distribution shift) ve genelleme sorunlarının önemini ortaya koymuştur.